BE530 – Medical Deep Learning

- Artificial Neural Networks -

Byoung-Dai Lee


Division of Al Computer Science and Engineering

Kyonggi University



Simple Regression (1)








Simple Regression – (2)




 $f_{\theta}(x) = Ax + B$

광고비	방문자수
58	374
70	385
81	375
84	401
95	481
107	502
113	495





Simple Prediction – (3)



Cost Function

$$E(\theta) = \frac{1}{n} \sum_{i=1}^{n} (y^{(i)} - f_{\theta}(x^{(i)}))^{2}$$

광고비	방문자수	5x+10	3x+150	0.1x+300
58	374	2401	937.57	17648.46
70	385			
81	375			
84	401			
95	481			
107	502			
113	495			



If Deep Learning is applied

- 1 A linear function
- ② $f_{\theta}(x) = 5x + 10$ $f_{\theta}(x) = 3x + 150$ $f_{\theta}(x) = 0.1x + 300$

주어진 학습데이터를 이용하여 E(θ)를 최소화시키는 모델의 θ를 자동으로 찾아냄

➡ Gradient Decent Method


(3)
$$E(\theta) = \frac{1}{n} \sum_{i=1}^{n} (y^{(i)} - f_{\theta}(x^{(i)}))^2$$

4
$$f_{\theta}(x) = 3x + 150$$




Perceptron (1)

A Perceptron with 2 inputs







- ※ 가중치 (weight: w₁, w₂)
 - 각 신호(e.g., x₁, x₂)가 결과에 주는 영향력을 조절하는 요소
 - 가중치가 클수록 해당 신호가 그만큼 더 중요함을 의미함



Perceptron (2)

Weights and Bias

$$y = \begin{cases} 0 \ (x_1 w_1 + x_2 w_2 \le \theta) \\ 1 \ (x_1 w_1 + x_2 w_2 > \theta) \end{cases} \qquad \qquad y = \begin{cases} 0 \ (b + x_1 w_1 + x_2 w_2 \le 0) \\ 1 \ (b + x_1 w_1 + x_2 w_2 > 0) \end{cases}$$


- ※ 가중치 (weight: w₁, w₂)
 - 각 입력 신호(e.g., x₁, x₂)가 결과에 주는 영향력을 조절하는 변수
- ※ 편향 (bias: b)
 - 뉴런이 얼마나 쉽게 활성화(결과로 1 출력)되는지를 조정하는 변수
 - 예) b=-0.1이면 각 입력 신호와 가중치를 곱한 값들이 합이 0.1을 초과할 때만 뉴런이 활성화. b=-20.0이면 입력 신호와 가중치를 곱한 값들이 합이 20을 초과하지 않으면 뉴런이 활성화되지 않음



Perceptron (3)

AND gate

$\mathbf{x_1}$	x ₂	у
0	0	0
1	0	0
0	1	0
1	1	1



OR gate

x ₁	X ₂	у	V
0	0	0	X ₂
1	0	1	
0	1	1	
1	1	1	

NAND gate

у	У	X ₂	$\mathbf{x_1}$	
1	1	0	0	
1	1	0	1	
1	1	1	0	
0	0	1	1	




Perceptron (4)

XOR gate

- Perceptron을 적용할 경우 XOR Gate에 대해 하나의 직선을 이용하여 0과 1을 구분할 수 없음
 - Perceptron은 직선 하나로 나눈 영역에 대해서만 표현 가능


X ₁	X ₂	У
0	0	0
1	0	1
0	1	1
1	1	0






Perceptron (5)

Multi-layer Perceptron (MLP)



x ₁	X ₂	S ₁	S ₂	у
0	0	1	0	0
1	0	1	1	1
0	1	1	1	1
1	1	0	1	0


- Single Layer Perceptron → 직선형 영역 표현
- Multi-Layer Perceptron → 비선형 영역 표현





Artificial Neural Networks

2-Layer ANN







Perceptron revisited

$$y = \begin{cases} 0 \ (b + x_1 w_1 + x_2 w_2 \le 0) \\ 1 \ (b + x_1 w_1 + x_2 w_2 > 0) \end{cases}$$

$$a = b + w_1 x_1 + w_2 x_2$$

$$y = h(a) = \begin{cases} 0 \ (a \le 0) \\ 1 \ (a > 0) \end{cases}$$





% h(a)

- 활성화 함수 (Activation Function)
- 입력 신호의 총합을 출력 신호로 변환
- Ex) step, sigmoid, ReLU, ···



Activation Functions


Step function

ReLU function

$$f(x) = \max(0, x)$$

Logistic sigmoid function

$$f(x) = \frac{1}{1 + e^{-x}}$$




Leaky ReLU function

$$f(x) = \max(0.1x, x)$$



Perceptron vs. ANN

- Perceptron과 Neural Network과의 주된 차이는 활성화 함수
 - Perceptron → step function
 - Neural networks → sigmoid, ReLU, …
- 신경망에서의 활성화 함수는 비선형 함수 사용
 - 선형 함수 사용 시 → 은닉층(Hidden Layer)을 사용하는 이점이 사라짐







Softmax Function

Output Layer

- Identity function(σ())
 - 입력 신호 = 출력 신호





Softmax function

$$p(c_k = 1 | \boldsymbol{x}) = \frac{\exp(y_k)}{\sum_{j=1}^{C} \exp(y_j)}$$

- 0에서 1.0사이의 출력
- 출력의 총합 = 1.0
- → Softmax function의 출력을 『확률』로 해석 가능



Loss Function

■ 학습 목표

Loss Function의 결과값을 최소화하는 가중치 매개변수 (w, b)를 찾는 것

$$\mathcal{L}(m{w}) = rac{1}{N} \sum_{i=1}^{N} l(m{w}, m{x}_i, t_i) + \mathcal{R}(m{w})$$
 $\stackrel{N: \text{ number of training examples}}{\mathcal{R}: \text{ regularizer}}$ $m{w}: \text{ set of all parameters}$

- 대표적인 손실 함수
 - 평균제곱오차(MSE: Mean Squared Error) Regression 문제


$$l = \frac{1}{2} \sum_{k} (y_k - t_k)^2, y_k: prediction, t_k: ground truth$$

• 교차 엔트로피 오차(CEE: Cross Entropy Error) – Classification 문제

$$\begin{split} l &= -\sum_{n=1}^N \sum_{k=1}^K d_{nk} log y_k(x_n; w) \\ d_n &= [d_{n1}, d_{n2}, \dots, d_{nk}] \text{ /* one hot encoding*/} \end{split}$$



Cross Entropy Loss (1)



$$p(C_k|x) = y_k = z_k^{(L)} = \frac{\exp(u_k^{(L)})1}{\sum_{j=1}^K \exp(u_j^{(L)})}$$
$$d_n = [d_{n1}, d_{n2}, \dots, d_{nK}] / * GT * /$$

Objective: E(w)를 최소화하는 w를 구할 수 있도록 학습

$$E(w) = -\sum_{n=1}^{N} \sum_{k=1}^{K} d_{nk} \log(y_k(x_n; w))$$

$$p(d|x) = \prod_{k=1}^{K} p(C_k|x)^{d_k}$$

*L(w)*에 로그를 취하고 부호 반전

L(w): 최대우도법 (maximum likelihood estimation)에 따른 w의 우도

$$L(w) = \prod_{n=1}^{N} p(d_n | x_n; w) = \prod_{n=1}^{N} \prod_{k=1}^{K} p(C_k | x)^{d_{nk}} = \prod_{n=1}^{N} \prod_{k=1}^{K} (y_k(x; w))^{d_{nk}}$$

Objective: *L(w)*를 최대화하는 w를 구할 수 있도록 학습




Cross Entropy Loss (2)

Cross entropy loss with Softmax function

$$l(\boldsymbol{w}, \boldsymbol{x}, t) = -\sum_{k=1}^{C} t^{(k)} \log p(c_k | \boldsymbol{x})$$

The output of the Softmax function

$$p(c_k = 1 | \mathbf{x}) = \frac{\exp(y_k)}{\sum_{j=1}^{C} \exp(y_j)}$$





Gradient Descent Method (1)

Given E(w), the gradient descent is defined as

$$\nabla E \equiv \frac{\partial E}{\partial w} = \left[\frac{\partial E}{\partial w_1}, \frac{\partial E}{\partial w_2}, \dots, \frac{\partial E}{\partial w_M} \right], M: w 의 성분수$$


- Gradient Descent Method
 - ullet 현재의 w를 음의 기울기 방향 $(-\nabla E)$ 로 조금씩 움직이는 것을 여러 번 반복
 - 현재의 가중치를 w^(t), 움직인 후의 가중치 w^(t+1) 를 라고 할 때 다음과 같이 갱신

$$w^{(t+1)} = w^{(t)} - \epsilon \nabla E$$
, ϵ : learning rate

- 학습률 (ϵ) 을 결정하는 것은 학습에서 매우 중요한 요소



Gradient Descent Method (2)






Backpropagation (1)

$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4






Backpropagation (2)

$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y \qquad rac{\partial q}{\partial x}=1, rac{\partial q}{\partial y}=1$$

$$f=qz$$
 $rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$






Backpropagation (3)

$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y \qquad rac{\partial q}{\partial x}=1, rac{\partial q}{\partial y}=1$$

$$f=qz \qquad \quad rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$$






Backpropagation (4)

$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y \qquad rac{\partial q}{\partial x}=1, rac{\partial q}{\partial y}=1$$

$$f=qz$$
 $rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$



Backpropagation (5)


$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y \qquad rac{\partial q}{\partial x}=1, rac{\partial q}{\partial y}=1$$

$$f=qz$$
 $rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$

Want: $\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial z}$



 $\frac{\partial f}{\partial z}$



Backpropagation (6)


$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y \qquad rac{\partial q}{\partial x}=1, rac{\partial q}{\partial y}=1$$

$$f=qz$$
 $rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$

Want: $\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial z}$



 $rac{\partial f}{\partial z}$



Backpropagation (7)


$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y \qquad rac{\partial q}{\partial x}=1, rac{\partial q}{\partial y}=1$$

$$f=qz$$
 $rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$

Want: $\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial z}$



KYONGGI UNIVERSITY


Backpropagation (8)

$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y \qquad rac{\partial q}{\partial x}=1, rac{\partial q}{\partial y}=1$$

$$f=qz \qquad \quad rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$$



Backpropagation (9)


$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y \qquad rac{\partial q}{\partial x}=1, rac{\partial q}{\partial y}=1$$

$$f=qz$$
 $rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$

Want: $\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial z}$



 $rac{\partial f}{\partial y}$

Backpropagation (10)


$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y \qquad rac{\partial q}{\partial x}=1, rac{\partial q}{\partial y}=1$$

$$f=qz$$
 $rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$

Want: $\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial z}$



Chain rule:

$$\frac{\partial f}{\partial y} = \frac{\partial f}{\partial q} \frac{\partial q}{\partial y}$$





Backpropagation (11)


$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y \qquad rac{\partial q}{\partial x}=1, rac{\partial q}{\partial y}=1$$

$$f=qz$$
 $rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$

Want: $\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial z}$



 $\frac{\partial f}{\partial x}$



Backpropagation (12)


$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y \qquad rac{\partial q}{\partial x}=1, rac{\partial q}{\partial y}=1$$

$$f=qz$$
 $rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$

Want: $\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial z}$




Chain rule:

$$\frac{\partial f}{\partial x} = \frac{\partial f}{\partial q} \, \frac{\partial q}{\partial x}$$




Backpropagation (13)






Backpropagation (14)






Backpropagation (15)






Backpropagation (16)






Backpropagation (17)





Backpropagation (18)






class AddLayer:

pass

def __init__(self):

Backpropagation (19)






class MulLayer:


def __init__(self):


Backpropagation (20)


ReLU

$$y = \begin{cases} x \ (x > 0) \\ 0 \ (x \le 0) \end{cases} \rightarrow \frac{\partial y}{\partial x} = \begin{cases} 1 \ (x > 0) \\ 0 \ (x \le 0) \end{cases}$$












Backpropagation (21)

Sigmoid

$$y = \frac{1}{1 + \exp(-x)}$$
 \rightarrow $\left(y = \frac{1}{x}, \frac{\partial y}{\partial x} = -\frac{1}{x^2} = -y^2 \right), \left(y = \exp(x), \frac{\partial y}{\partial x} = \exp(x) \right)$






Backpropagation (22)

Sigmoid (cont.)

$$y = \frac{1}{1 + \exp(-x)}$$

$$\frac{\partial L}{\partial y} y^2 \exp(-x) = \frac{\partial L}{\partial y} \frac{1}{(1 + \exp(-x))^2} \exp(-x) = \frac{\partial L}{\partial y} \frac{1}{1 + \exp(-x)} \frac{\exp(-x)}{1 + \exp(-x)} = \frac{\partial L}{\partial y} y(1 - y)$$



```
class Sigmoid:
    def __init__(self):
        self.out = None

def forward(self, x):
        out = 1 / (1+np.exp(-x))
        self.out = out

    return out

def backward(self, dout):
    dx = dout * (1.0 - self.out)*self.out


return dx
```




Backpropagation Example (1)

2-layer ANN

- MSE Loss function: $E(\theta) = \frac{1}{2} \sum_{k} (y_k t_k)^2$
- 입력 차원 (d), 부류 개수 (c), 은닉층 노드 수 (p), one-hot encoding
- Layer 1 가중치 행렬: U¹ (p×d), Layer 2 가중치 행렬: U² (c×p)





(b) u_{ii}1이 미치는 영향



Backpropagation Example (2)

$$\frac{\partial E}{\partial u_{kj}^{2}} = \frac{\partial (0.5||y - f(U^{1}, U^{2})||_{2}^{2})}{\partial u_{kj}^{2}}
= \frac{\partial (0.5 \sum_{q=1}^{c} (y_{q} - o_{q})^{2})}{\partial u_{kj}^{2}} = \frac{\partial (0.5 (y_{k} - o_{k})^{2})}{\partial u_{kj}^{2}}
= -(y_{k} - o_{k}) \frac{\partial (o_{k})}{\partial u_{kj}^{2}} = -(y_{k} - o_{k}) \frac{\partial \tau (osum_{k})}{\partial u_{kj}^{2}}
= -(y_{k} - o_{k}) \tau' (osum_{k}) \frac{\partial (osum_{k})}{\partial u_{kj}^{2}}
= -(y_{k} - o_{k}) \tau' (osum_{k}) z_{i}$$


$$\delta_k = (y_k - o_k)\tau'(osum_k), 1 \le k \le c$$

$$\frac{\partial E}{\partial u_{kj}^2} = -\delta_k z_j, 0 \le j \le p, 1 \le k \le c$$

 $x_0=1$



Backpropagation Example (3)



$$\begin{split} \frac{\partial E}{\partial u_{ji}^{1}} &= \frac{\partial (0.5\|y - f(U^{1}, U^{2})\|_{2}^{2})}{\partial u_{ji}^{1}} \\ &= \frac{\partial (0.5\sum_{q=1}^{c}(y_{q} - o_{q})^{2})}{\partial u_{ji}^{1}} = -\sum_{q=1}^{c}(y_{q} - o_{q})\frac{\partial (o_{q})}{\partial u_{ji}^{1}} \\ &= -\sum_{q=1}^{c}(y_{q} - o_{q})\tau'(osum_{q})\frac{\partial (osum_{q})}{\partial u_{ji}^{1}} \\ &= -\sum_{q=1}^{c}(y_{q} - o_{q})\tau'(osum_{q})\frac{\partial (osum_{q})}{\partial z_{j}}\frac{\partial (z_{j})}{\partial u_{ji}^{1}} \\ &= -\sum_{q=1}^{c}(y_{q} - o_{q})\tau'(osum_{q})u_{qj}^{2}\frac{\partial (z_{j})}{\partial u_{ji}^{1}} \end{split}$$



Backpropagation Example (3)

 $x_0=1$

$$z_{j} = \tau(zsum_{j}), j = 1, 2, ..., p$$

$$zsum_{j} = u_{j}^{1} \times x, u_{j}^{1} = (u_{j0}^{1}, u_{j1}^{1}, ..., u_{jd}^{1}), x = (1, x_{1}, x_{2}, ..., x_{d})^{T}$$

$$= -\sum_{q=1}^{c} (y_q - o_q) \tau'(osum_q) u_{qj}^2 \frac{\partial(z_j)}{\partial u_{ji}^1}$$

$$= -\sum_{q=1}^{c} (y_q - o_q) \tau'(osum_q) u_{qj}^2 \tau'(zsum_j) x_i$$

$$= -\tau'(zsum_j)x_i \sum_{q=1}^{c} (y_q - o_q) \tau'(osum_q)u_{qj}^2$$

$$\delta_k = (y_k - o_k)\tau'(osum_k), 1 \le k \le c$$

$$\frac{\partial E}{\partial u_{kj}^2} = -\delta_k z_j, 0 \le j \le p, 1 \le k \le c$$

$$\eta_{j} = \tau'(zsum_{j}) \sum_{q=1}^{c} \delta_{q} u_{qj}^{2}, 1 \leq j \leq p$$

$$\frac{\partial E}{\partial u_{ii}^{1}} = -\eta_{j} x_{i}, 0 \leq i \leq d, 1 \leq j \leq p$$



Training Process (1)

- 배치 학습 (batch learning)
 - ullet 모든 훈련 샘플에 대해 계산되는 $E_n(w)$ 의 합을 오차함수로 사용

$$E(w) = \sum_{n=1}^{N} E_n(w)$$

- 확률적 경사 하강법 (SGD: Stochastic Gradient Descent)
 - 샘플의 일부, 극단적으로는 샘플 하나만을 사용하여 가중치 업데이트 수행
 - DNN에서는 배치 학습보다는 SGD를 더 많이 사용



Training Process (2)

Minibatch

● 샘플 한 개 단위가 아니라 몇 개의 샘플을 하나의 작은 집합으로 묶은 단위 (e.g., minibatch)로 가중치 업데이트 수행

$$E(w) = \frac{1}{N_t} \sum_{n \in D_t}^{N} E_n(w), N_t = |D_t|$$

- 일반적으로 $D_t(t=1,2,...)$ 는 학습 시작 전에 결정하여 고정
 - 미니배치의 크기는 대체로 10~100개 샘플 전후로 결정하는 경우가 많음
 - 클래스의 수가 10~100개 정도이면서 클래스의 출현 빈도가 서로 같을 경우 분류하려는 클래스 수와 같은 크기의 미니배치를 생성하는 것이 좋음
 - 클래스 수가 그 이상인 경우 샘플을 랜덤으로 섞은 후에 미니배치를 분할




Training Process (3)

The objective of training process

$$\boldsymbol{w}^* = \underset{\boldsymbol{w}}{\operatorname{argmin}} \frac{1}{N} \sum_{i=1}^{N} l(\boldsymbol{w}, \boldsymbol{x}_i, t_i) + \mathcal{R}(\boldsymbol{w})$$

At each iteration, we need to compute





Vanishing Gradient Program (1)

■ Vanishing Gradient란?




- NN의 depth가 깊어지게 되면 $w_{n+1} = w_n \alpha \times \nabla f (= \frac{\partial f}{\partial x})$ 에서 gradient(e.g., $\frac{\partial f}{\partial x}$)가 아주 작은 값을 가지게 되며, 따라서 Input Layer에 가까운 Layer일 수록 w에 변화가 거의 없어지게 됨
- Why does it happen?
 - $\frac{\partial L}{\partial x} = \frac{\partial z}{\partial x} \frac{\partial L}{\partial z}$ 가 되며 이 중 하나의 항이라도 0에 가까울수록 $\frac{\partial L}{\partial x}$ 는 0에 가까워지며 결과 적으로 $\alpha \times \nabla f$ 이 0에 가까워짐에 따라 w_{n+1} 과 w_n 이 변화가 없게 됨
 - Sigmoid 함수를 사용하게 될 경우 함수가 saturation이 되는 부분에서는 기울기의 변화가 거의 없으며 따라서 $\frac{\partial z}{\partial x}$ (e.g., local gradient)가 0에 가깝게 됨
 - Output Layer에서 가까운 neuron이 항상 1에 가까운 값을 낼 경우, 즉 Saturation 될 경우 그 neuron과 연결된 앞쪽 Layer에서 사용되는 w는 거의 변화가 없어지게
 - → Error의 Backpropagation이 제대로 이루어지지 않음



Vanishing Gradient Problem (2)

■ ReLU 함수를 사용할 경우

- ReLU는 x가 0보다 큰 경우 선형적으로 증가하기 때문에 $\frac{\partial z}{\partial x}$ (e.g., local gradient)가 0이 되는 경우는 발생하지 않음. 따라서 gradient가 0에 근접하는 경우는 발생하지 않음
- 그러나 특정 neuron이 선택되지 않는 경우 (즉, ReLU의 output이 0이 발생하는 구간)에는 local gradient, 즉 $\frac{\partial z}{\partial x}=0$ 이 됨. 따라서 해당 neuron과 연결된 앞쪽 neuron의 경우 gradient가 항상 0이 되기 때문에 w에 변화가 발생하지 않음





Parameter Updates (1)

SGD

$$W \leftarrow W - \eta \, \frac{\partial L}{\partial W}$$

Momentum

$$v \leftarrow \alpha v - \eta \frac{\partial L}{\partial W}$$
$$W \leftarrow W + v$$

AdaGrad

 각각의 매개변수를 대상으로 학습률 감소(learning rate decay) 적용


$$h \leftarrow h + \frac{\partial L}{\partial W} \cdot \frac{\partial L}{\partial W}$$
$$W \leftarrow W + \eta \frac{1}{\sqrt{h}} \frac{\partial L}{\partial W}$$


Adam

Momentum + AdaGrad




Parameter Updates (2)








Initialization (1)



가중치를 표준편차가 1인 정규분포로 초기화할 때의 각 층의 활성화값 분포




가중치를 표준편차가 0.01인 정규분포로 초기화할 때의 각 층의 활성화값 분포




Initialization (2)

- 각 층의 활성화값 (활성화 함수의 출력 데이터)은 적당히 골고루 분포되어야 함
 - 층과 층 사이에 적당하게 다양한 데이터가 흐르게 해야 신경망 학습이 효율적으로 이루어짐
 - 반대로 치우친 데이터가 흐르면 기울기 소실이나 표현력 제한 문제에 빠져 학습이 잘 이루어지지 않는 경우 발생



데이터가 0과 1에 치우쳐지게 분포

- → Sigmoid 함수의 Saturation Point
- → Vanishing Gradient 문제 발생




다수의 뉴런의 유사한 값 출력

→ 뉴런을 여러 개 둔 의미가 없어짐 (100개의 뉴런이 같은 값을 가질 경우 1개의 뉴런으로 구성하는 것과 동일



Initialization (3)

- Xavier Initialization
 - 표준편차가 $\binom{1}{\sqrt{n}}$ 인 정규 분포로 가중치 초기값 설정 (n) 앞 층의 노드 수)




• Sigmoid, tanh 등 활성화 함수가 선형일 때 사용 (좌우 대칭 형태이므로 중앙 부근이 선형으로 볼 수 있음



Initialization (4)

- He Initialization
 - 표준편차가 $\binom{1}{\sqrt{n/2}}$ 인 정규 분포로 가중치 초기값 설정 (n: 앞 층의 노드 수)



• 활성화 함수로 ReLU 함수를 사용할 때 사용




Initialization (5)

- Bias Initialization
 - Bias는 0으로 초기화하는 것이 보편적
 - ReLU를 사용할 경우 0.01과 같은 작은 값으로 초기화하면 성능 향상 효과 가 있다는 보고도 있으나 모든 경우 그렇지는 않음




Initialization (6)

■ 활성화 함수로 ReLU를 사용한 경우 가중치 초기값에 따른 활성화값 분포 변화




표준편차가 0.01인 정규분포

- → 역전파 시 가중치의 기울기 역시 작아짐
- → 학습이 거의 이루어지지 않음



Xavier 초기값

→ Vanishing Gradient 문제 발생 가능




He 초기값

→ 층이 깊어져도 분포가 모든 층에서 균일하게 분포



Wrap-Up

Multi-Layer Perceptron



• 학습 목표 → Loss function

$$\mathcal{L}(\boldsymbol{w}) = \frac{1}{N} \sum_{i=1}^{N} l(\boldsymbol{w}, \boldsymbol{x}_i, t_i) + \mathcal{R}(\boldsymbol{w})$$

학습 방법 → Gradient Descent Method

$$W \leftarrow W - \eta \, \frac{\partial L}{\partial W}$$

References

- CS231n: Convolutional Neural Networks for Visual Recognition, http://cs231n.stanford.edu/
- 라온피플 머신러닝 아카데미, https://laonple.blog.me/
- 밑바닥부터 시작하는 딥러닝, 한빛미디어
- 기초 수학으로 이해하는 머신러닝 알고리즘, 위키북스
- 딥러닝 제대로 시작하기, 제이펍
- 기계학습, 한빛아카데미





