

Chest Radiograph Disentanglement for COVID-19 Outcome Prediction

Medical Deep-Learning 3rd Paper review

Kyonggi Univ. Smart I.O.T Lab 이상민 (2021년 12월 01일)

목차



01. Introduction

02. Method

03. Experiments

04. Conclusion

01. Introduction

Chest radiographs

흉부 방사선 사진은 CT에 비해 많은 정보를 가지진 못하지만, 교차감염위험이 낮고 널리 사용이 가능하기에 COVID-19의 주요 진단 도구

COVID-19에 감염된 경우 흉부 방사선 사진에서 흉부의 구조적인 변화는 없지만, 폐 조직 질감이 급격히 변경되었음을 관찰

따라서, 질병에 대한 진단에는 흉부의 구조적인 형태보다 질감의 변화가 더 유효하다는 것을 가정

이러한 가설은 흉부 방사선 사진에서 COVID-19가 폐 영역 내의 혼탁으로 관찰되고 범위와 위치가 질병의 중증도 및 진행과 관련이 있다는 최근 연구에 의해 증빙되었다.

01. Introduction

Chest radiographs

CT를 기반으로 한 모델들이 방사선 사진을 기반으로 한 모델들 보다 COVID-19 예측을 더 잘 해낸다.

이유는 COVID-19관련 **방사선 사진의 부족**과 CT에 비해 방사선 사진은 포함하는 정보가 적기 때문

또한 CT관련 데이터 증강 연구는 많이 진행되었지만, 방사선 사진에 대해서는
공개 데이터 셋에 의존하는 경향과 종종 질병의 정보가 부족한 경우가 있기 때문

GAN, AutoEncoder를 통한 의료 데이터 증강에 많이 사용되었지만,
GAN 기반의 증강의 경우 왜곡이 발생할 수 있기 때문에 **방사선 사진 생성에 적합하지 않다.**

01. Introduction

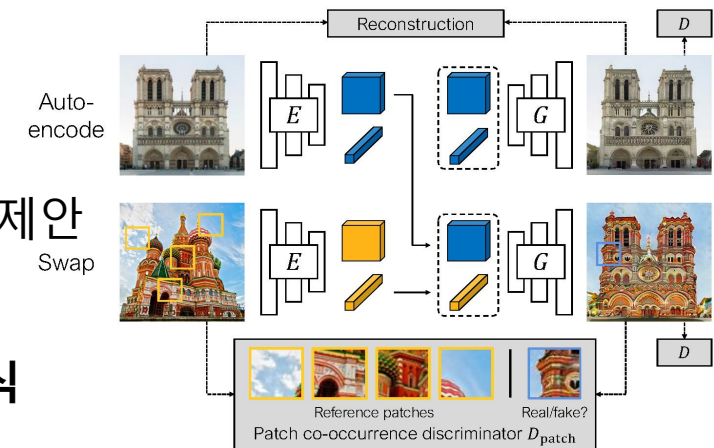
Chest radiographs

데이터 부족 문제를 해결하기 위해서 Lung Swapping Auto Encoder를 제안

흉부 방사선 사진에서 구조와 질감을 분리 후
다른 흉부 구조에 질감을 부여하여 새로운 이미지를 만들어내는 방식

해당 아이디어는 SAE (Swapping AutoEncoder)와 핵심 아이디어를 공유하지만,
SAE는 전체 이미지를 대상으로 샘플링된 패치를 활용하여서
텍스처를 합성하기 때문에 **흉부 방사선 사진에서는 잘 동작하지 않는다.**

그 이유는 전체 이미지에서 텍스처 패치를 샘플링할 경우 폐 외부의 텍스처가 폐 내부의 텍스처에 영향을 끼쳐 폐 내부의 **텍스처 전송의 효과를 감소**시키기 때문이며,
이러한 과정에서 원치 않는 **폐 모양의 왜곡이 발생**하여서
흉부 방사선 사진의 구조와 질감의 분리 과정에 안 좋은 영향을 끼치기 때문



01. Introduction

Chest radiographs

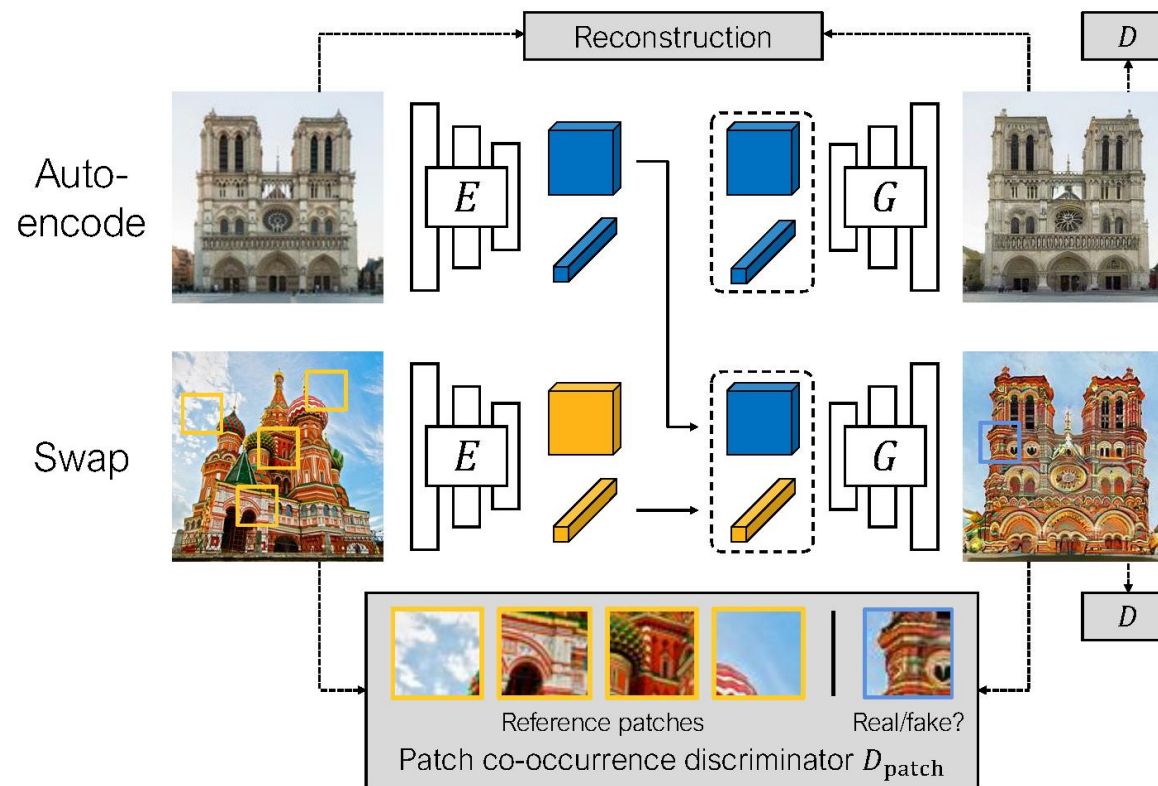
효과적인 데이터 증강을 위해서 전체 이미지에서 텍스처 패치를 생성하는 것이 아닌, 폐 영역 내부에서 패치 샘플링을 진행.

또한 구조 정보가 변경되는 것을 방지하기 위해서 패치 대비 손실을 추가
대규모 공개 흉부 방사선 사진 데이터 셋인 ChestX-ray14를 사용하여
한 환자의 폐 구조와 다른 환자의 질병 질감을 사용하여 현실적인
하이브리드 **흉부 방사선 사진을 생성.**

이러한 데이터 증강을 통해 흉부 방사선 사진을 통한 질병 분류에 문제에서
기존의 모델들 보다 효과적이며, COVID-19 예측 문제에서도 더욱 향상된 결과를 보임.

02. Method

Swapping Auto Encoder (SAE)

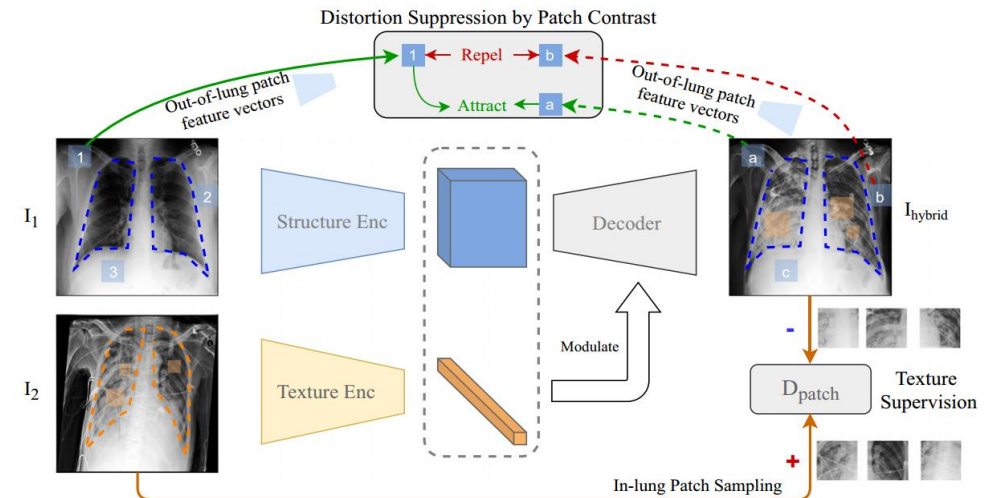


02. Method

Lung Swapping Auto Encoder (LSAE)

$$I_1, I_2 \xrightarrow{Enc} \begin{cases} (z_1^s, z_1^t) \\ (z_2^s, z_2^t) \end{cases} \rightarrow (z_1^s, z_2^t) \xrightarrow{Dec} I_{hybrid}$$

$$G(I_1, I_2) \stackrel{def}{=} Dec(Enc^s(I_1), Enc^t(I_2))$$



02. Method

LSAE Loss function

재구성 손실 $L_{recon} = E_{I_1 \sim X} \|G(I_1, I_1) - I_1\|_1$

생성자 손실 $L_G = E_{I_1, I_2 \sim X} -\log(D(G(I_1, I_1))) - \log(D(G(I_1, I_2)))$

Texture 왜곡 손실(폐 영역 내부) $L_{inTex} = E_{\substack{\tau_1, \tau_2 \sim \tau_{LungMask}^{in} \\ I_1, I_2 \sim X}} \left[-\log(D_{patch}(\tau_1(I_2), \tau_2(G(I_1, I_2)))) \right]$

structure 왜곡 손실(폐 영역 외부) $L_{sup} = E_{\substack{\{\tau\}_N \sim \tau_{LungMask}^{out} \\ I_1, I_2 \in X}} \sum_h^H \sum_i^N l_{NCE}(\tau_i(Enc_h^s(I_{hybrid})), \{\tau(Enc_h^s(I_1))\}_N)$


Cross-entropy loss N-way classification problem

$$l_{NCE}(q_i, \{p\}_N) = -\log \left(\frac{\exp\left(\frac{q_i * P^+}{\alpha}\right)}{\exp\left(\frac{q_i * P^+}{\alpha}\right) + \sum_{j=1}^{N-1} \exp\left(\frac{q_i * p_j^-}{\alpha}\right)} \right)$$

$$\text{총합 손실 } \mathbf{L} = L_{recon} + \lambda_1 L_G + \lambda_2 L_{inTex} + \lambda_3 L_{sup}$$

02. Method

LSAE Result



02. Method

Data Argmentation with Hybrid images

I_2 의 texture를 I_{hybrid} 로 전송할 수 있다면, I_2 의 레이블도 I_{hybrid} 로 전송되었다고 가정.

이러한 가정을 기반으로 $I_{dst}(texture)$ 가 주어진다면 $I_{src}(structure)$ 로 k개의 I_{hybrid} 이미지 생성

여기에서 I_{dst} 는 COVOC 데이터셋을 사용하였으며, I_{src} 는 ChestX-ray14를 사용하였습니다.

이러한 증강 기법을 사용하여서 훈련 셋을 k배로 확장이 가능

해당 증강의 실험 결과는 Table 2에서 확인 가능하며, 이러한 증강 기법을 통해서 예측의 정확도를 더욱 향상 시킬 수 있음을 보여줌.

03. Experiments

Implementation, Dataset

Library	Pytorch 1.7
Base architectures	StyleGAN2
Input image size	256x256
Sampling patch size	16x16 ~ 64x64
Loss function parameter	$\lambda_1 = 0.5$ $\lambda_2 = 1$, $\lambda_3 = 1$
α	0.07
Optimizer	Adam, initial learning rate = $1e-3$ (0.001)
Image Preprocessing	histogram equalization

Name	ChestXray14
amount	32,717 patients, 112,120 images
Use	Train(70%), validation(10%), test(20%)
ETC.	동일한 환자의 이미지는 세트 중 하나에만 나타냄.

Name	COVID-19 outcome (COVOC)
Amount	327 patients, 340 images
Use	Train(250), validation(30), test(60)

03. Experiments

Evaluation Protocol

생성된 이미지와 기존 이미지의 질병 수준을 파악하기 위해서 Masked SIFID를 제안

Masked SIFID는 기존의 Inception V3를 기반으로 한 SIFID를 기반으로 하며,
폐 내부 영역의 특징만을 비교합니다.

추가적으로 5명의 흉부 방사선 전문의에게 설문조사를 통해 피드백을 요청

4개의 질문을 통해 생성된 이미지의 평가를 한 결과

생성된 이미지의 56%를 실제의 이미지로 평가하였고

하이브리드 이미지 패치의 76%를 실제 이미지로 평가하였다.

또한 Masked SIFID 방식의 질문을 한 결과 78.67%가 같은 답변을 하였으며,

마지막 질문으로 동일한 질감을 가진 원본 이미지와 생성된 이미지를 보여주었을 때
60%가 테스트를 통과하였습니다.

04. Conclusion

Table 1. Left. On the hybrid image generation task

Right. For the 14 pulmonary diseases classification task on ChestXray14

Method	Masked SIFID ↓	mIoU ↑	Pixel Acc ↑	Dice ↑
Init	0.0335	0.60	0.82	0.72
SAE	0.0257	0.76	0.91	0.85
LSAE	0.0245	0.91	0.97	0.95

Pre-train	Method	Params	mAUC ↑
Sup	CXR14-R50[24]	23M	0.745
	ChestNet [23]	60M	0.781
	CheXNet* [16]	7M	0.789
	Inception v3	22M	0.796
Unsup	<i>Enc^t</i>	5M	0.790

04. Conclusion

Table 2. COVOC Outcome Prediction

BER(%)	Inception V3	Enc^t in SAE	Enc^t in LSAE	Enc^t in LSAE + Data aug
Split 1	20.25 \pm 1.46	20.25 \pm 1.63	19.00 \pm 1.84	
Split 2	19.25 \pm 3.67	20.50 \pm 1.12	17.75 \pm 1.66	
Split 3	17.75 \pm 3.48	14.00 \pm 1.85	12.75 \pm 2.15	
Avg	19.08	18.25	16.50	15.67

mAUC(%)	Inception V3	Enc^t in SAE	Enc^t in LSAE	Enc^t in LSAE + Data aug
Split 1	85.45 \pm 1.89	89.03 \pm 2.16	89.17 \pm 0.68	
Split 2	86.02 \pm 1.27	85.63 \pm 1.77	87.07 \pm 1.91	
Split 3	89.12 \pm 1.38	92.60 \pm 1.25	95.00 \pm 0.29	
Avg	86.86	89.09	90.41	92.04

04. Conclusion

LSAE를 통해서 구조와 질감을 분리하여, COVID-19 및 기타 질병 관련 조직 변화를 분석할 수 있으며, 이렇게 분리된 구조와 질감을 통해서 효과적인 데이터 증강을 할 수 있다.

이러한 방법을 통해서 기존의 COVID-19 예측 모델의 성능을 능가하며, 개선된 의사 결정을 가능케하였다.

추후에는 COVID-19 외 다른 질병에 적용할 예정이다.

Question



감사합니다!