

# 의료 영상 시스템에서 다중 연쇄 U-Net 모델을 이용한 췌장 영역 분할 탐지

🕒 생성일	@2022년 5월 13일 오후 8:31
👤 저자	이상민
📖 학회	
📅 발표일	
📍 장소	
☑ 속성	<input type="checkbox"/>

1. 표3에서 U-Net모델에 비해 A U-Net과 RSTN의 정확도가 낮은 이유를 설명해 주세요.

Attention U-Net은 "Attention U-Net: Learning Where to Look for the Pancreas" 논문의 result에서 볼 수 있듯이 오차범위내에서 정확도가 나오 고 있으며, Attention U-Net의 실험결과 Epoch이 3,6,10,60,150 순으로 진행되며, 점점 더 성능이 좋아지는 것을 볼 수 있으며, 해당 논문에서는 모 델의 학습을 Epoch 10까지 진행하였기에, Attention U-Net보다 제안한 모델의 성능이 더 높은것을 알 수 있습니다. 여러 모델간의 정량적인 비교를 위해 Epoch를 더 늘려서 실험을 진행하지 않았습니다. 또한 더 많은 Epoch를 진행하였을 경우에도 정량적인 결과에 변화는 크지않을것이라고 생각 하였기 때문입니다.




Figure 4: The figure shows the attention coefficients ( $\alpha^{l_2}$ ,  $\alpha^{l_3}$ ) across different training epochs (3, 6, 10, 60, 150). The images are extracted from sagittal and axial planes of a 3D abdominal CT scan from the testing dataset. The model gradually learns to focus on the pancreas, kidney, and spleen.

Table 1: Multi-class CT abdominal segmentation results obtained on the CT-150 dataset: The results are reported in terms of Dice score (DSC) and mesh surface to surface distances (S2S). These distances are reported only for the pancreas segmentations. The proposed Attention U-Net model is benchmarked against the standard U-Net model for different training and testing splits. Inference time (forward pass) of the models are computed for input tensor of size  $160 \times 160 \times 96$ . Statistically significant results are highlighted in bold font.

Method	Train / Test Split	Panc. DSC	Panc. Precision	Panc. Recall	S2S Dist (mm)
U-Net [22]	120 / 30	0.814±0.116	0.848±0.110	0.806±0.126	2.358±1.464
Attention U-Net	120 / 30	<b>0.840±0.087</b>	0.849±0.098	<b>0.841±0.092</b>	<b>1.920±1.284</b>
U-Net [22]	30 / 120	0.741±0.137	0.789±0.176	0.743±0.179	3.765±3.452
Attention U-Net	30 / 120	<b>0.767±0.132</b>	<b>0.794±0.150</b>	<b>0.762±0.145</b>	3.507±3.814

Method	Train / Test Split	Spleen DSC	Kidney DSC	Number of Pars	Inference Time
U-Net [22]	120 / 30	0.962±0.013	0.963±0.013	5.88 M	0.167 s
Attention U-Net	120 / 30	0.965±0.013	0.964±0.016	6.40 M	0.179 s
U-Net [22]	30 / 120	0.935±0.095	0.951±0.019	5.88 M	0.167 s
Attention U-Net	30 / 120	<b>0.943±0.092</b>	0.954±0.021	6.40 M	0.179 s

Recurrent Saliency Transformation Network의 원 논문의 실험 표 2와 표 3을 보면, 본래 RSTN의 성능이 약 84.5%에 도달하는 것을 볼 수 있고, 표 3의 pancreas 탐지 정확도는 네트워크의 미세 조정을 통해서 이루어진 제일 높은 정확도를 나타낸 것이기 때문에 평균적으로 보았을 때에는 약 84.5%인 것을 알 수 있으며, 이러한 이유로 비교를 위한 실험을 진행한 결과 또한 84.5%로 나타난 것을 볼 수 있습니다.

Approach	Average	Max	Min
Roth <i>et al.</i> [34]	71.42 ± 10.11	86.29	23.99
Roth <i>et al.</i> [35]	78.01 ± 8.20	88.65	34.11
Zhang <i>et al.</i> [44]	77.89 ± 8.52	89.17	43.67
Roth <i>et al.</i> [36]	81.27 ± 6.27	88.96	50.69
Zhou <i>et al.</i> [46]	82.37 ± 5.68	90.85	62.43
Cai <i>et al.</i> [3]	82.4 ± 6.7	90.1	60.0
Our Best Model	<b>84.50 ± 4.97</b>	<b>91.02</b>	<b>62.81</b>

Table 2. Accuracy (DSC, %) comparison between our approach and the state-of-the-arts on the NIH pancreas segmentation dataset [34]. [44] was implemented in [46].

Organ	[46]-C	[46]-F	Ours-C	Ours-F
<i>adrenal g.</i>	57.38	61.65	60.70	<b>63.76</b>
<i>duodenum</i>	67.42	69.39	71.40	<b>73.42</b>
<i>gallbladder</i>	82.57	<sup>#</sup> 82.12	87.08	<b>87.10</b>
<i>inferior v.c.</i>	71.77	<sup>#</sup> 71.15	79.12	<b>79.69</b>
<i>kidney l.</i>	92.56	92.78	96.08	<b>96.21</b>
<i>kidney r.</i>	94.98	95.39	95.80	<b>95.97</b>
<i>pancreas</i>	83.68	85.79	86.09	<b>87.60</b>

Table 3. Comparison of coarse-scaled (C) and fine-scaled (F) segmentation by [46] and our approach on our own dataset. A fine-scaled accuracy is indicated by # if it is lower than the coarse-scaled one. The *pancreas* segmentation accuracies are higher than those in Table 2, due to the increased number of training samples and the higher resolution in CT scans.

A U-Net, RSTN 모두 비교를 위한 실험의 정확도는 원 논문을 잘 구현하여 실험을 진행한 것을 알 수 있었으며, 정량적인 비교 표 2를 보면 우리가 제안하는 MCU-Net의 결과가 기존의 A U-Net, RSTN의 성능 보다 좋은 것을 확인할 수 있습니다. 이러한 추가 분석은 표 3 밑 부분에 추가로 정리하여 작성하였습니다.

2. 표2, 표3의 실험과 관련해서 학습 속도에 대한 분석을 추가해 주세요.

논문에 학습 속도에 관해서는 이야기 하지 않았지만, Attention U-Net 모델은 attention gate를 사용함으로써 U-Net에 비해 학습시간이 약간 더 길었으며, 저희가 제안하는 MCU-Net은 기존 U-Net 모델의 개선을 위해 정확도에 초점을 맞추어 앙상블, 패치 크기 변환을 중점적으로 진행하였으며, 표 2에 나와있는 앙상블 유무, 패치 크기의 변화로 인해서 학습 시간은 많은 편차가 있으며, 학습 속도를 비교하는 것은 저희의 연구 결과에서는 주요한 맹점이 아니라고 생각하였으며, 추후 연구를 통해 학습 속도 등 모델의 성능을 나타내는 다양한 지표에 대한 분석도 진행할 예정입니다. 이러한 부분을 실험 단락 속 제안하는 모델을 설명하는 단락에 추가 작성하였습니다.

3. 딥러닝 모델의 성능이 초매개변수에 영향을 받게 되는데 논문처럼 실험에 의한 수치로 비교해도 되는지에 대한 설명이 필요합니다.

Epoch : 10, learning rate : 1e-5, optimizer : Adam, Loss function : Dice coefficient

으로 설정하여서 학습을 진행하였으며, Epoch 10이상 될 경우 overfitting되어 정확도가 떨어지는 결과를 보았기에 더 이상에 학습을 진행하지 않았고, 동일한 초매개변수를 사용하여서 딥러닝 모델 구조 변화에 따른 정확도 변화추이를 정량적으로 비교하기 위해서 고정된 초매개변수를 사용하였으며, 이러한 내용을 실험 단락에 추가하여 작성하였습니다.

수정요청사항:

- 3쪽 “~ 특징 벡터 을 추출하고”에 오류가 있는 것 같습니다.
- 2 쪽 II 관련 연구 마지막 부분 “~ 그러나 RSTN은 지나치게 긴 학습 시간을 요구한다. 따라서 본 논문에는 ~”에서 “따라서”의 의미가 명확하지 않습니다. 즉, 따라서 전, 후 문장이 내용상 호응하지 않습니다.

수정요청사항 또한 수정 작성하였습니다.